

GKD: Generalized Knowledge Distillation for Auto-regressive Sequence Models

这是一篇关于知识蒸馏的文献，后以 On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes 为名发表于 ICLR 2024。该文的核心是提出 GKD 框架：用 λ 控制固定数据与学生生成轨迹的比例，用散度 D 选择如何控制师生分布，并拓展了蒸馏与强化学习结合。

背景

传统的自回归模型蒸馏主要受制于两大问题。

- 1、训练阶段和推理阶段的输出序列分布不匹配（模仿学习中的经典难题）；
- 2、模型表达能力不足（model under-specification）：学生模型通常比教师小，未必能完整拟合教师的概率分布；

为解决第一个问题，作者让学生在训练时自己生成输出，再由教师在这些输出上提供指导；为解决第二个问题，作者采用逆向 KL 或广义 JSD 等散度。

KL 散度（相对熵）

设 P 、 Q 为同一随机变量空间上的两个概率分布，KL 散度（前向 KL）的离散形式如下：

$$\mathcal{D}_{KL}(P\|Q) = \sum_{c \in \mathcal{C}} P(c) \log \frac{P(c)}{Q(c)}$$

它衡量的是用概率分布 Q 近似 P 时带来的额外信息代价。这里的权重来自 $P(c)$ ，因此 P 认为重要的区域，对损失的贡献更大。在蒸馏中，可以把 P 理解为教师分布，把 Q 理解为学生分布。

KL 散度不对称。 $\mathcal{D}(P\|Q)$ 和 $\mathcal{D}(Q\|P)$ 的数值与优化效果通常不同。论文中称前者为前向 KL，交换顺序后的形式称为逆向 KL：

$$\mathcal{D}_{RKL}(P\|Q) = \mathcal{D}_{KL}(Q\|P) = \sum_c Q(c) \log \frac{Q(c)}{P(c)}$$

前向 KL 按教师分布 P 加权；逆向 KL 则按学生分布 Q 加权。这一差别决定了它们重点惩罚什么：若 $P(c) > 0$ 而 $Q(c) = 0$ ，前向 KL 会发散；若 $Q(c) > 0$ 而 $P(c) = 0$ ，逆向 KL 会发散。实际模型使用 softmax 时概率通常不为零，但极低概率区域也会带来较强惩罚。

前向 KL 为什么对应最大似然

论文有一句话：经验数据分布下的前向 KL 对应最大似然。这里假设固定训练集包含 N 个样本， P 表示这个数据集诱导的经验分布， Q 表示待训练的模型。展开前向 KL 后，化简后得到：

$$\mathcal{D}_{KL}(\hat{P}\|Q_\theta) = C - \frac{1}{N} \sum_{i=1}^N \log Q_\theta(c_i)$$


其中 C 只由经验分布决定，不依赖模型参数 θ 。

不难看出，最小化 KL 等价于最大化训练样本的对数似然。这说明了前向 KL 与监督学习的联系；如果教师提供完整 logits 分布，蒸馏能利用比单一 token 更多的信息。

前向 KL 与逆向 KL 的行为差异

前向 KL 具有 mode-covering（模式覆盖）倾向：教师在哪些地方给了概率，学生就需要尽量覆盖这些地方。假如教师分布有多个峰，而学生只能表示单峰，学生可能把分布拉宽，以同时照顾多个峰，结果却在教师低概率的中间区域也分配了概率。

逆向 KL 具有 mode-seeking（模式寻求）倾向：它更强地约束学生不要把概率放在教师不认可的区域，而不要求学生同等覆盖教师的每一个模式。因此，容量有限的学生可以集中学习某个高概率模式。论文用双峰分布和单峰近似说明此。



这也是为什么论文采用逆向 KL 的原因，当学生的表达能力弱于教师时，与其强行拟合所有可能续写，不如优先把生成概率放在教师认为合理的区域。

JSD 散度

KL 在支撑不重合时可能发散，而 JSD 散度对 $0 < \beta < 1$ 有界。它先构造混合分布 M_β ，再比较 P 、 Q 与这个混合分布的差异：

$$M_\beta = \beta P + (1 - \beta)Q$$

$$D_{\text{JSD}[\beta]}(P||Q) = \beta D_{\text{KL}}(P||M_\beta) + (1 - \beta) D_{\text{KL}}(Q||M_\beta)$$

β 较小时，其优化行为接近前向 KL； β 接近 1 时，更接近逆向 KL。

三种训练方式

第一种是监督微调 SFT。只有固定的输入输出配对数据 (X, Y) ，不需要教师提供分布。学生最大化参考输出的似然：

$$\mathcal{L}_{\text{SFT}}(\theta) = \mathbb{E}_{(x,y) \sim (X,Y)} [-\log p_s^\theta(y|x)]$$

第二种是监督知识蒸馏 supervised KD（Hinton 提出）。训练轨迹仍来自固定数据，但在每个前缀上，学生需要匹配教师完整的下一 token 分布：

$$\mathcal{L}_{\text{SD}}(\theta) = \mathbb{E}_{(x,y) \sim (X,Y)} [d_{\text{KL}}(x, y)]$$

相比 SFT，该方法提供的信息更丰富。问题在于：这些教师指导仍然发生在教师自身轨迹，未必覆盖学生推理时会遇到的前缀。

第三种是 OPD，即学生在自己的生成轨迹上学习。先让学生根据 x 生成 y ，再由教师指导，这里采用前向 KL：

$$\mathcal{L}_{\text{OnD}}(\theta) = \mathbb{E}_{x \sim X} \mathbb{E}_{y \sim p_s(\cdot|x)} [d_{\text{KL}}(x, y)]$$

它的关键变化是训练状态来自学生。学生即使生成了不理想的前缀，教师也在这个前缀上告诉它下一步怎样选择。这样，训练就更贴近学生推理时的输出分布。

GKD 统一以上方法

以上方法关注数据来源或散度选择。GKD 联合二者：既允许使用固定输出，也允许学生生成输出；既允许前向 KL，也允许逆向 KL、JSD 等散度。

$$\mathcal{L}_{GKD}(\theta) = (1 - \lambda)\mathbb{E}_{(x,y) \sim (X,Y)}[d_{\mathcal{D}}(x,y)] \\ + \lambda\mathbb{E}_{x \sim X}\mathbb{E}_{y \sim p_S(\cdot|x)}[d_{\mathcal{D}}(x,y)]$$

第一项在固定数据轨迹上蒸馏，第二项在学生轨迹上蒸馏。 $\lambda \in [0, 1]$ 控制学生生成数据在训练中的比例。

$\lambda=0$ 且 D 为前向 KL 时，就是监督 KD； $\lambda=1$ 且 D 为前向 KL 时，就是 on-policy KD； $0 < \lambda < 1$ 时，两种轨迹混合使用。 $\lambda=1$ 而 D 取其他散度时，就得到广义的 on-policy GKD。

算法流程

Algorithm 1 Generalized Knowledge Distillation (GKD)

- 1: **Given:** Teacher model p_T , Student Model p_S^θ , Dataset (X, Y) contain input contexts x and possibly output sequences y .
 - 2: **Hyperparameters:** Student data fraction $\lambda \in [0, 1]$, Divergence $\mathcal{D}$, Learning rate η
 - 3: **for** each step $k = 1, \dots, K$ **do**
 - 4: Generate a random value $u \sim \text{Uniform}(0, 1)$
 - 5: **if** $u \leq \lambda$ **then**
 - 6: Sample batch of contexts from X and for each x , sample one output $y \sim p_S^\theta(\cdot|x)$ to obtain $B = \{(x_b, y_b)\}_{b=1}^B$
 - 7: **else**
 - 8: Sample batch of contexts and outputs from (X, Y) to obtain $B = \{(x_b, y_b)\}_{b=1}^B$.
 - 9: Update θ to minimize L_{GKD} : $\theta \leftarrow \theta - \eta \frac{1}{B} \sum_{(x,y) \in B} \nabla_{\theta} \mathcal{D}(p_T \| p_S^\theta)(y|x)$
-

GKD 与强化学习结合

得益于 OPD 的性质，GKD 与强化学习结合非常简单。可以构建如下场景：教师行为不一定等于真正优化目标。如果能定义序列奖励信号 $r(y)$ ，就可以用强化学习直接学习，同时用 GKD 约束学生保持接近教师。论文中也给出了相应框架：

$$J(\theta) = (1 - \alpha)\mathbb{E}_{x \sim X}\mathbb{E}_{y \sim p_S^\theta(\cdot|x)}[r(y)] \\ - \alpha\mathbb{E}_{x \sim X}\mathbb{E}_{y \sim p_S(\cdot|x)}[d_{\mathcal{D}}(x,y)]$$

第一项是奖励项，第二项约束惩罚，限制学生偏离教师。

我本周的认识

1. 我意识到我目前对领域了解仍然不多。比如上周 NLP 大组组会，某老师问演讲同学，SFT 和 OPD 有什么区别，OPD 好在哪？我当时确实没意识到 OPD 的好处，通过此文的学习，我发现，On-policy 通过在学生自身轨迹上学习，确实缓解了训练和推理序列分布的偏差；并且 SFT 粗粒度的 token 级信号提供的信息密度不如监督 KD 和 GKD 等。

2. 调研的作用巨大。我不能想当然，既费时间也低。对于 OPD 在扩散模型上的可能的现象，我会尽量去了解前人工作。