2026.10.27 组会

目标

在不损失性能的情况下，利用具有潜力的 token 给掩码扩散语言模型加速解码。

参考

1、OPTD https://arxiv.org/pdf/2608.02942

2、COPSD https://aclanthology.org/2026.findings-acl.1344.pdf

3、dOPSD https://arxiv.org/pdf/2607.04428

4、d-OPSD https://arxiv.org/pdf/2606.18195

数据与轨迹采集

数据	设置
训练集	GSM8K 随机 2000 题
测试集	GSM8K 完整 1319 题；MATH-500 完整 500 题
轨迹采样	best of 4

训练配置

参数	设置
基模	Efficient-Large-Model/Fast_dLLM_v2_1.5B
硬件	NVIDIA A100 40GB PCIE
解码阈值	0.9
稳定性阈值	0.8
损失权重	0.5
生成设置	块长 32，开放子块 8，GSM8K 最长 512，MATH-500 最长 1024 token
LoRA	rank = 8，alpha = 16，作用于全部注意力层的 q、v 投影
优化器	AdamW，学习率 5×10^{-5}
训练耗时	29 分钟

测试结果

测试集	模型	准确率	平均前向次数	平均耗时
GSM8K (1,319)	基模	61.41% (810)	102.93	2.70 秒
GSM8K (1,319)	想法	59.59% (786)	80.97	2.10 秒
MATH-500 (500)	基模	38.20% (191)	212.87	5.67 秒
MATH-500 (500)	想法	30.00% (150)	184.45	5.09 秒

GSM8K 准确率下降 1.82%，前向次数减少 21.3%，加速约 1.29 倍。

MATH-500 准确率下降 8.20%，前向次数减少 13.4%，加速约 1.11 倍。

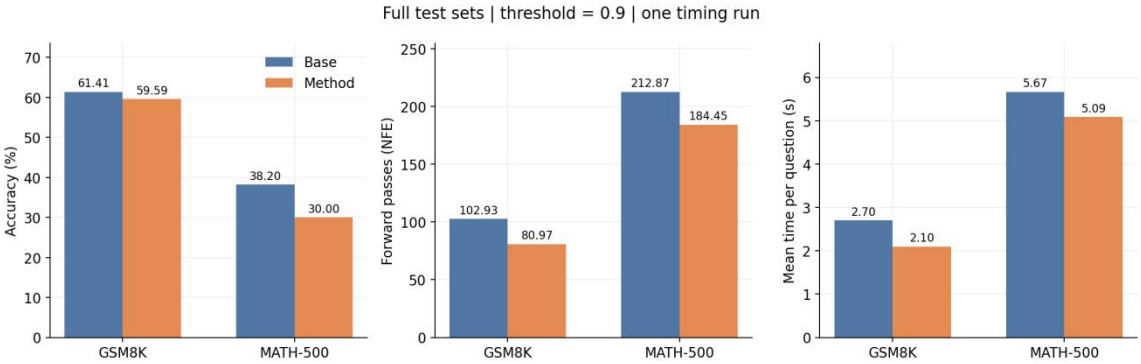


图 1　基模与方法的准确率、平均前向次数和平均耗时

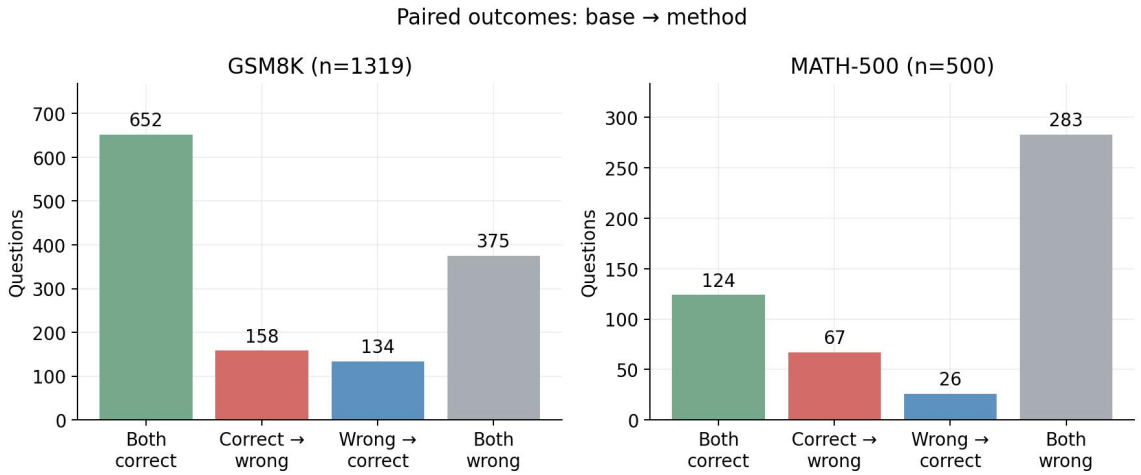


图 2　基模与想法在测试集的答题情况

当前判断与后续规划

基模经过想法的 Lora 微调后，在 GSM8K 测试集上表现出较好的速度收益，同时保持较小的性能损失。但在 MATH-500 上虽然速度有提升，但性能损失明显。

但 MATH-500 上性能的损失目前无法判断，是训练、想法还是两者都有的原因造成的。打算再在基模上做 SFT Lora 微调，如果 MATH-500 测试后也有性能损失，说明 GSM8K 的定向训练确实会带来跨任务损失。如果 SFT 后模型在 MATH-500 测试集上表现与基模差不多，说明想法有问题。

我个人认为是，想法的潜在稳定 token 的判断机制仍然粗糙，导致模型过度自信。预测稳定不等于提前释放安全，如果模型更早地释放了可能会大幅度改变基模原本当前状态的 token，后续推理可能被较大影响，这里，时间稳定性阈值 beta 责任很大，因为它可能会把分布在不同释放步骤的 token 告诉学生去提前同步释放，这可能使得学生进入原始轨迹中没有出现的状态，MATH 的符号运算和长推理可能会放大这种问题。想法的核心目标应该是在尽量保持原有后续预测和最终结果一致的前提下，将多个去噪步骤合并，以减少前向次数。
下面的想法是，修改损失目标，当前损失目标只关注了潜力 token，这样做法的坏处前面已说。目前打算修改损失目标使得剩余位置的预测尽量接近原轨迹走到后续状态时的预测，即实现状态跳步。
另外，对于潜在稳定 token 的判断机制也需修改。尝试重要性分配，具体来说，对于初步选定的潜力 token，时间稳定性打分考虑添加权重，越往后预测，预测正确的重要性逐步降低。
最后，没做超参数调参，这也可能是效果没达到预期的部分原因。